基于六度理论的演员关系搜索

吴行行

朱雨

2017-07-27

目录

1 数据集

数据集是来自 IMDb 互联网电影数据库的截至 2017 年份所有上映电影和演员数据，共有 70 万部电影，96 万位演员。首先进行预处理和统计，将原数据集处理成 “演员 + 出演电影列表” 和 “电影 + 演员列表” 两个数据文件。统计得到每个演员平均出演 3.99 部电影，每个电影平均有 8.5 个演员。

2 算法

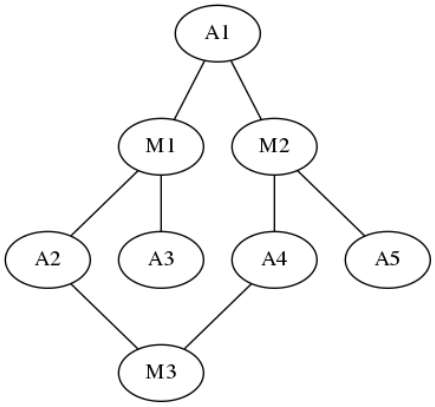

Figure 1: model

图1是算法采用的模型，其中 A 表示演员，M 表示电影，演员出演电影则两个节点存在一条边。所有数据构成一个无向有环图，问题转化成在图中查找两个 A 节点之间的路径。采用 Breadth-First-Search 算法。

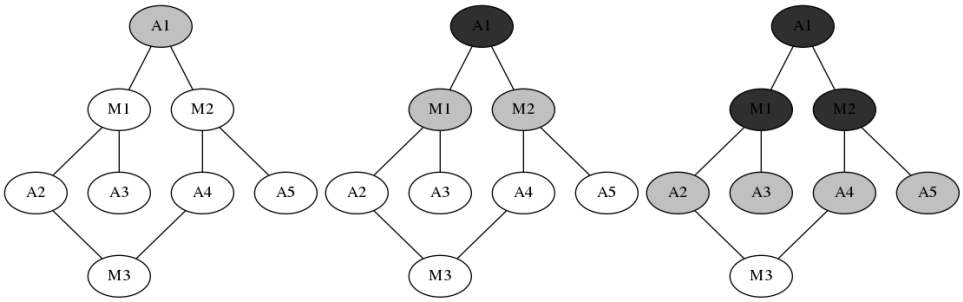

(a) bfs:1 (b) bfs:2 (c) bfs:3

Figure 2: BFS

灰色点表示 open 点，黑色点表示 close 点，白色点表示 unknown 点。

每一轮更新 open 节点和 close 节点，将 open 节点的邻节点中的 unknown 节点加入 open 表，并将本轮的 open 节点变为 close 节点，循环进行下去，直到在 open 节点中发现目标节点，或者遍历深度达到上限值 (6*2+1=13)。

3 Hadoop 实现

3.1 输入数据

所有节点及其子节点 <name, children>;

已经处理过的节点 <name,children,distance,status,parent>。

3.2 Map 阶段

所有节点发送 <name,children>

已经处理过的节点发送 <name,distance,status,parent>

open 节点发送 <child,distance,parent>

3.3 Reduce 阶段

接收到 children 数据，用于组成新的 open 节点

接受到 distance,status,parent 数据，则已经是 close 节点

接收到 parent's distance 数据，则成为新的 open 节点

写入所有的 close 节点数据和新的 open 节点数据：<name,children,distance,status,parent>

4 优化

4.1 优化 close 节点数据

对于 close 节点，不再需要 children,distance,status,parent 数据，只需要保留 name 即可。能够减小写入文件大小和 M-R 之间传输的数据。

4.2 优化 open 数据

Map 阶段所有节点都需要发送 <name,children> 数据，但是 Reduce 中只有新的 open 节点才需要这个数据。

上一轮中保存下一轮会 open 的节点 name，Map 的时候只发送新 open 节点的数据。通过 CacheFile 传送这个数据。

当然 CacheFile 文件不能太大，否则会 heap 溢出并且查询时间过长，这里取深度为 6 以上的时候就不再使用 CacheFile，而是采用原来的办法发送所有数据。

4.3 搜索索引信息

当前的搜索过程中，每一次迭代都需要读取当前的节点，进行全部节点的一次搜索，可以考虑通过预处理得到一些索引信息，能够减少搜索的深度和范围。比如预处理得到演员的一度表（即两个演员出演过同一部电影，他们的关系称为一度），这样利用索引信息只需要迭代最多六次就能够完成搜索。但是一度表相比原先的数据变得特别大，因为原先的父子节点关系现在变成了祖孙节点关系，中间节点的信息仍然需要存储。实际运行中，发现一度表的数据量是原先数据的 60 倍，虽然搜索深度降低了，但是巨大数据量带来的读文件，切片，分配给各个 mapper 带来的开销同样很大，最终结果得不偿失，也就停止了这方面的工作。

4.4 倒排索引缓存

想法来自于搜索引擎的规律，20% 的内容能够满足 80% 的搜索。因此可以通过一定的方法找出最可能被用户搜索的一些演员，然后把这些演员的两两组合作为 key，他们之间的路径 (预先计算好) 作为 value，然后对于这些演员可以直接通过查找这个倒排索引表命中。现有数据集中可以利用的数据有电影名字，演员名字，出演时间，演员角色在电影中的排名。综合考虑决定利用演员出演电影数量和角色排名两个信息，前者保证了演员能够较多的出现在荧幕中，后者保证了演员在电影中的地位较重要。最终使用的公式为:

$$Score(actor) = \sum_{m \in MovieList} \frac{1 + number_m - rank_m}{number_m}$$

其中 MovieList 是 actor 所有出演的电影，number 是电影中角色总数量，rank 表示 actor 在电影中的排名。但是数据集中部分 rank 信息缺失，通过人为观察计算结果，发现缺失情况下当期项取 1/2 较好，即默认演员在电影中排名居中。用户查询的时候，首先搜索是否在倒排索引表中，命中时间少于 100ms，即使不命中，这个开销也是特别小的。

4.5 去除干扰数据

数据集中存在一些娱乐和新闻等类型的剧集，比如美国早间新闻以及各种脱口秀节目。这些节目的演员列表中包含了很多电影明星，我们认为这种情况下并不能算作两个演员互相认识，视为干扰数据。干扰数据的最大特征就是演员数量巨多，剧集持续时间较长。首先根据演员数目将数据排序，根据 IMDb 提供的节目分类将其中的 “talk show” “news” 类的节目去除。

5 结果

6 总结

这次实验选择了自己感觉很有趣的项目，熟悉了分布式系统下 BFS 算法的实现和优化方向，通过一点一点的多方面的优化，能够在 106s 之内完成搜索。实验还发现大部分的演员满足四度关系，也验证了六度分割理论。

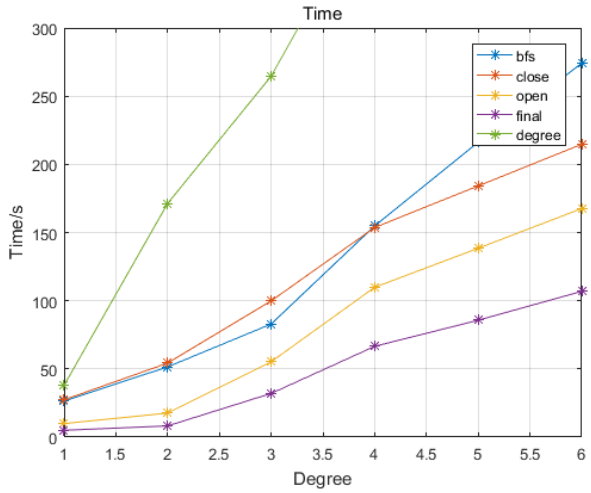

(a) time

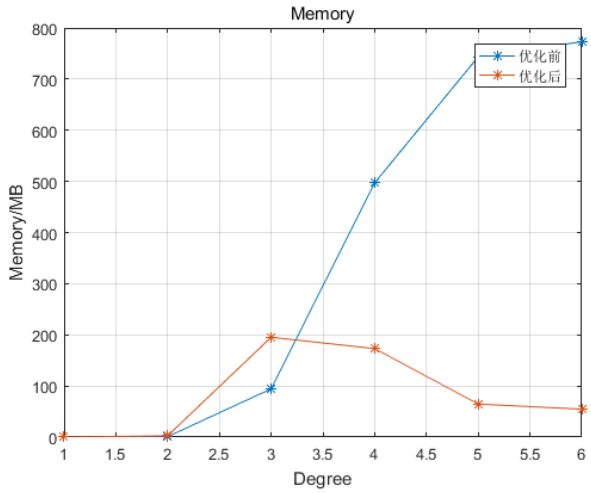

(b) memory

Figure 3: 时间开销和空间开销